



**MÜHENDİSLİK, MİMARLIK VE TASARIM FAKÜLTESİ**  
**BİLGİSAYAR MÜHENDİSLİĞİ**

**Ders : Yapay Zeka**

**Konu: Derin Öğrenme ile Meyve Sınıflandırması  
ve Optimizasyon Algoritmalarının Karşılaştırılması**

**Hazırlayanlar:**

**Sina Rahbaribanaeian\_23670310047**

**Mehmet İpek\_23010310039**

**Şeyda Nur Okcu\_23010310054**

**Dilara Çınar\_23010310024**

**Ders öğretim üyesi : Doç.Dr.Hakan Öcal**

## 1. Model ve Veri Seti Hakkında Kısa Açıklama

Bu projede, görüntü işleme tabanlı meyve sınıflandırması için bir Evrişimli Sinir Ağı (Convolutional Neural Network - CNN) modeli geliştirilmiştir. Çalışmada "Fruit-360" veri setinden rastgele seçilen 15 farklı meyve sınıfı (Cantaloupe 2, Apple 23, Nut 4, Limes 1, Grapefruit Pink 1, Cherry Rainier 3, Cactus fruit 1, Blackberry 1, Quince 3, Apple 8, Apple 7, BlackBerry 4, Grape White 2, Kaki 1, Apple 5) kullanılmıştır.


Modelin temel amacı, farklı optimizasyon algoritmalarının eğitim sürecindeki doğruluk (accuracy), kayıp (loss) ve stabilite performanslarını analiz etmektir.

### 1.1 . Geliştirilen CNN modeli temel olarak aşağıdaki katmanlardan ve özelliklerden oluşmaktadır:


- Giriş Katmanı:** Meyve görüntülerinin modele alındığı başlangıç katmanıdır.
- Evrişim (Conv2D) ve Havuzlama (MaxPooling2D) Katmanları:** Görüntülerden renk, kenar ve doku gibi temel özniteliklerin çıkarılmasını ve önemli bilgileri koruyarak boyut küçültülmesini sağlar.
- Düzleştirme (Flatten):** Çıkarılan öznitelikler 16384 boyutlu vektöre dönüştürülerek tam bağlantılı (Dense) katmana hazır hale getirilir.
- Tam Bağlantılı Katman (Dense):** 128 nöronlu karar/öğrenme katmanıdır.
- Dropout Katmanı (%50):** Ağdaki nöronların %50'si rastgele inaktif edilerek modelin eğitim verisini ezberlemesi (overfitting) önlenmiştir.
- Çıkış Katmanı (Softmax):** 15 farklı meyve sınıfı için olasılık dağılımı üreterek nihai sınıflandırmayı gerçekleştirir.

**CNN Model Mimarisi ve Parametre Dağılımı**  
(Toplam Parametre: 2,118,991)

| Katman Türü        | Çıktı Boyutu       | Parametre |
|--------------------|--------------------|-----------|
| Conv2D             | (None, 64, 64, 32) | 896       |
| BatchNormalization | (None, 64, 64, 32) | 128       |
| MaxPooling2D       | (None, 32, 32, 32) | 0         |
| Conv2D             | (None, 32, 32, 64) | 18496     |
| BatchNormalization | (None, 32, 32, 64) | 256       |
| MaxPooling2D       | (None, 16, 16, 64) | 0         |
| Flatten            | (None, 16384)      | 0         |
| Dense              | (None, 128)        | 2097280   |
| Dropout            | (None, 128)        | 0         |
| Dense              | (None, 15)         | 1935      |



**Görüntülerin Analizi:** Veri setinden alınan meyve fotoğrafları incelendiğinde, görüntülerin standardize edilmiş bir yapıda olduğu görülmektedir. Görüntüler, beyaz ve temiz bir arka plana sahip olup nesne merkezde yer almaktadır. Bu durum, Evrişimli Sinir Ağı (CNN) modelinin arka plandaki gürültülerle (noise) uğraşmadan doğrudan meyvenin rengine, dokusuna ve şekline odaklanmasını sağlamıştır. Görüntülerin sahip olduğu bu yüksek kalite, özellikle Adam ve Adamax gibi adaptif algoritmaların ilk birkaç epokta çok yüksek doğruluk (%99+) oranlarına ulaşmasındaki en büyük etkenlerden biridir.



Eğitimde kullanılan final sınıf listesi: ['Apple 23', 'Apple 5', 'Apple 7', 'Apple 8', 'BlackBerry 4', 'Blackberry 1', 'Cactus fruit 1', 'Cantaloupe 2', 'Cherry Rainier 3', 'Grape White 2', 'Grapefruit Pink 1', 'Kaki 1', 'Limes 1', 'Nut 4', 'Quince 3']  
Her sınıftaki resim sayısı: {150}

**Sınıf Dağılımı Analizi:** Veri setinde yer alan 15 farklı meyve sınıfına ait görüntü sayılarını ifade eden sütun grafikleri (histogram) incelendiğinde, eğitim ve test (veya doğrulama) verilerinin sınıflar arasındaki dağılımı görülmektedir. Sütunların yükseklikleri, sınıflar arasında çok büyük veri dengesizlikleri (data imbalance) olmadığını, modelin her bir meyve türünden yeterli sayıda örneği görerek öğrenebildiğini kanıtlamaktadır. Dengeli veri dağılımı, modelin belirli bir sınıfa karşı önyargılı (bias) olmasını engellemiş ve genel doğruluk oranını artırmıştır.

## 1.2. Literatür Taraması

- Bu projede kullanılan CNN mimarisi, veri seti seçimi ve optimizasyon algoritmalarının teorik temellerini oluşturmak amacıyla literatürdeki temel çalışmalar incelenmiştir:
- **Meyve Sınıflandırması ve Fruit-360 Veri Seti:** Mureşan ve Oltean (2018) tarafından yapılan "Fruit recognition from images using deep learning" başlıklı çalışmada "Fruit-360" veri seti literatüre kazandırılmış ve Evrişimli Sinir Ağları (CNN) kullanılarak meyve tanıma işlemlerinin son derece yüksek doğrulukla yapılabileceği kanıtlanmıştır. Bu çalışma, projemizin temel veri seti seçimi ve sınıflandırma yaklaşımı için ana referans noktası olmuştur.
- **Derin Öğrenme ve CNN Mimarisi:** Goodfellow, Bengio ve Courville (2016) tarafından kaleme alınan "Deep Learning" adlı kapsamlı eser, projede kurulan CNN modelinin katman yapısı (Conv2D, MaxPooling, Dropout vb.), kayıp fonksiyonlarının hesaplanması ve aşırı öğrenmenin (overfitting) önlenmesi gibi konularda temel teorik altyapıyı sağlamıştır.
- **Optimizasyon Algoritmalarının Gelişimi:** Modelin eğitim sürecinde karşılaştırılan algoritmaların tarihsel ve matematiksel gelişimi incelendiğinde; Duchi ve arkadaşları (2011) "Adaptive Subgradient Methods..." isimli çalışmalarıyla uyarlanabilir (adaptif) öğrenme oranına sahip Adagrad algoritmasını tanıtarak literatürde büyük bir yeniliğe imza atmıştır. İlerleyen yıllarda Kingma ve Ba (2014), "Adam: A Method for Stochastic Optimization" adlı makalelerinde Adam algoritmasını sunmuş; bu yöntemin momentum ve uyarlanabilir öğrenme katsayılarını birleştirerek büyük veri setlerinde ve karmaşık derin öğrenme ağlarında çok daha hızlı, kararlı ve başarılı bir yakınsama (convergence) sağladığını matematiksel olarak kanıtlamışlardır.
- Bu projede de literatürdeki bu teorik temeller ve iddialar baz alınmış, ilgili algoritmaların pratikteki (meyve sınıflandırması üzerindeki) performansları karşılaştırmalı olarak analiz edilmiştir.

## 2. Optimizasyon Algoritmalarının Teorik Altyapısı

Bu projede, geliştirilen Evrişimli Sinir Ağı (CNN) modelinin öğrenme sürecini optimize etmek, kayıp (loss) fonksiyonunu en aza indirmek ve ağırlık güncellemelerini en verimli şekilde gerçekleştirmek amacıyla dört farklı optimizasyon algoritması test edilmiştir. Performans karşılaştırması için kullanılan algoritmaların temel çalışma prensipleri aşağıda özetlenmiştir:

### **Stokastik Gradyan İnişi (SGD - Stochastic Gradient Descent):**

**Tanım:** Derin öğrenme modellerinde kullanılan en temel optimizasyon yöntemlerinden biridir. Model ağırlıklarını tüm veri seti üzerinden hesaplamak yerine, her adımda rastgele seçilen tek bir eğitim örneği veya küçük bir veri grubu (mini-batch) üzerinden günceller.

**Avantaj:** İşlem yükünü azaltarak eğitim sürecini hesaplama açısından önemli ölçüde hızlandırır.

**Dezavantaj:** Her adımda rastgele veri kullandığı için hedefe giden yolda dalgalanmalara (kararsız adımlara) neden olabilir. Sabit bir öğrenme oranına (learning rate) sahip olduğu için karmaşık veri setlerinde yerel minimumlara (local minima) takılıp en iyi sonuca (global minimum) ulaşamama riski taşır.

### **Adagrad (Adaptive Gradient Algorithm):**

**Tanım :**Adagrad, her bir parametre için öğrenme oranını eğitim süreci boyunca dinamik olarak uyarlayan bir algoritmadır.

**Avantaj :**sık güncellenen öznitelikler için öğrenme oranını düşürürken, nadir görülen öznitelikler için öğrenme oranını yüksek tutar. Bu özelliği sayesinde özellikle seyrek (sparse) veri setlerinde başarılı sonuçlar verir.

**Dezavantaj :** geçmiş gradyanların karelerinin sürekli toplanması nedeniyle öğrenme oranının zamanla çok küçülmesi ve bir noktadan sonra modelin yeni şeyler öğrenmeyi durdurmasıdır.

### **Adam (Adaptive Moment Estimation):**

**Tanım:** Momentum ve RMSprop algoritmalarının en iyi özelliklerini bir araya getiren bir optimizasyon yöntemidir. Ağırlık güncellemeleri sırasında sadece geçmiş gradyanların hareketli ortalamasını (birinci moment) değil, aynı zamanda geçmiş gradyanların karelerinin hareketli ortalamasını da (ikinci moment) hesaplar.

**Avantaj:** Her bir parametre için öğrenme oranını adaptif (dinamik) olarak günceller. Büyük veri setlerinde ve karmaşık CNN yapılarında çok hızlı yakınsama (convergence) sağlar. Günümüzde en sık tercih edilen algoritmalarından biri olup, son derece kararlı ve yüksek doğrulukta sonuçlar verir.

**Dezavantaj:** Her bir parametre için hem birinci hem de ikinci momentleri hesaplayıp hafızada tutması gerektiğinden, standart optimizasyon algoritmalarına kıyasla daha fazla bellek (RAM) tüketir. Çok hızlı öğrenmesine rağmen, bazı özel durumlarda SGD (Stokastik Gradyan İnişi) kadar iyi genelleme (generalization) yapamayabilir.

## Adamax :

**Tanım:** Adam algoritmasının L2 normu yerine sonsuzluk normuna (infinity norm) dayalı olarak geliştirilmiş bir varyantıdır. Parametre güncellemeleri sırasında gradyanların maksimum mutlak değerini dikkate alarak öğrenme oranını ayarlar.

**Avantaj:** Çok büyük gradyan değerlerine karşı (örneğin veri setinde aykırı değerlerin olduğu durumlarda) Adam'a kıyasla daha dirençli ve kararlı bir yapı sunar. Özellikle çok fazla parametreye sahip olan karmaşık modellerde (ağır CNN mimarilerinde) zaman zaman Adam'dan daha iyi ve stabil bir optimizasyon performansı gösterebilmektedir.

**Dezavantaj:** Çoğu standart ve daha az karmaşık derin öğrenme probleminde orijinal Adam algoritmasına belirgin bir üstünlük sağlayamaz; bu nedenle genel kullanımdaki yaygınlığı Adam kadar yüksek değildir. Diğer adaptif yöntemler gibi, bazı özel durumlarda genelleme (generalization) kapasitesi açısından klasik SGD'nin (Momentum ile) gerisinde kalabilir.



## 3. Eğitim Süreci ve Performans Metrikleri

Bu bölümde, geliştirilen 15 sınıflı Evrişimli Sinir Ağı (CNN) modelinin "Fruit-360" veri seti üzerindeki eğitim süreci incelenmiş; Adam, Adagrad, Adamax ve SGD optimizasyon algoritmalarının performansları Kayıp (Loss), Doğruluk (Accuracy) ve Karmaşıklık Matrisi (Confusion Matrix) metrikleri üzerinden analiz edilmiştir. Elde edilen grafikler ve matrisler doğrultusunda modelin öğrenme karakteristiği aşağıda detaylandırılmıştır:


### 3.1. Eğitim ve Doğrulama Kaybı (Loss) Analizi

Farklı optimizasyon algoritmalarına ait kayıp fonksiyonu grafikleri incelendiğinde, algoritmaların hatayı minimize etme hızlarında ve eğri karakteristiklerinde belirgin farklar tespit edilmiştir:


- **Adam ve Adamax:** Her iki adaptif optimizasyon algoritması da eğitim sürecine çok hızlı bir giriş yapmış ve ilk 2-3 epok içerisinde kayıp (loss) değerini 0.0 bandına kadar düşürmüştür. Doğrulama kaybı (val\_loss) eğrileri de eğitim eğrileriyle büyük bir uyum içinde seyretmiş, bu durum modelin aşırı öğrenmeye (overfitting) düşmeden hatayı başarılı bir şekilde sıfırladığını göstermiştir.



- **SGD (Stokastik Gradyan İnişi):** Sabit öğrenme oranına sahip SGD algoritmasının kayıp grafiği, adaptif algoritmalara kıyasla daha farklı bir yapı sergilemiştir. Başlangıçta 1.8 ile 2.0 seviyelerinde olan eğitim kaybı, keskin bir düşüş yerine daha ılımlı ve kademeli bir şekilde azalmıştır. 10. epok tamamlandığında kayıp değeri ancak 0.2 - 0.3 seviyelerine inebilmiştir. Ayrıca, SGD'nin doğrulama kaybı eğrisinde zaman zaman yukarı yönlü dalgalanmalar gözlemlenmiş olup, bu durum algoritmanın adaptif yöntemler kadar pürüzsüz bir yakınsama (convergence) sağlayamadığına işaret etmektedir.





- **Adagrad:** Başlangıç epoklarında hızlı bir hata düşüşü sergilemesine rağmen, algoritmanın doğası gereği geçmiş gradyanların birikmesiyle öğrenme oranının aşırı küçülmesi (sönümlenmesi) problemi yaşanmıştır. Bu sebeple ilerleyen epoklarda kayıp eğrisi belirli bir noktada platoya (düzlüğe) girmiş ve hata değerindeki iyileşme duraksamıştır.





### 3.2. Eğitim ve Doğrulama Doğruluğu (Accuracy) Analizi

Modelin doğru sınıflandırma kapasitesini yansıtan Accuracy (Doğruluk) grafikleri, algoritmaların öznetelik çıkarma ve öğrenme hızlarını açıkça ortaya koymuştur:

- **Adam ve Adamax:** Doğruluk grafikleri incelendiğinde, bu iki algoritmanın eğitim verisi üzerinde sadece 2 ila 3 epok içinde %99-%100 (0.99 - 1.0) doğruluğa ulaştığı görülmektedir. Aynı yüksek performans doğrulama (validation) veri setinde de gözlemlenmiş, model test verilerindeki meyveleri de neredeyse kusursuz bir şekilde tanımayı başarmıştır.




- **SGD:** SGD algoritması, eğitime nispeten düşük bir seviye olan %40 (0.40) doğrulukla başlamıştır. Epok sayısı arttıkça doğruluk oranı istikrarlı ancak yavaş bir artış trendi yakalamış ve 10. epokun sonunda yaklaşık %95 (0.95) seviyelerine ulaşmıştır. Bu durum, SGD'nin hedefe doğru güvenli adımlarla ilerlediğini ancak minimum hataya ulaşmak için Adam veya Adamax'a kıyasla çok daha fazla iterasyona ihtiyaç duyduğunu kanıtlamaktadır.






### 3.3. Karmaşıklık Matrisi (Confusion Matrix) Analizi


Modelin sınıflandırma başarımlarını ve hangi sınıfları birbirleriyle karıştırdığını detaylı görebilmek için test verileri üzerinden oluşturulan karmaşıklık matrisleri incelenmiştir:




- **Kusursuz Sınıflandırma ve Ayırt Edici Sınıflar:** Adam ve Adamax algoritmalarına ait karmaşıklık matrisleri incelendiğinde, modelin tahminlerinin neredeyse tamamının matrisin ana köşegeni (diagonal) üzerinde yoğunlaştığı tespit edilmiştir. Özellikle "Nut 4", "Cactus fruit 1" ve "Grapefruit Pink 1" gibi renk ve form açısından belirgin karakteristik özelliklere sahip meyveler, tüm optimizasyon algoritmalarında Yanlış Pozitif (False Positive) veya Yanlış Negatif (False Negative) üretmeden %100 başarıyla sınıflandırılmıştır.



- Sınıf Benzerliklerinden Kaynaklanan Hatalar (Apple 7 - Apple 8):** SGD ve özellikle Adagrad algoritmalarının karmaşıklık matrislerinde belirgin yanlış sınıflandırmalar göze çarpmaktadır. Veri setinde görsel yapı, şekil ve renk pigmentasyonu açısından birbirine çok benzeyen "Apple 7" ve "Apple 8" sınıfları model tarafından sıkça karıştırılmıştır. Matris verilerine göre; gerçekte "Apple 7" sınıfına ait olan bazı görüntüler model tarafından "Apple 8" olarak tahmin edilmiş, benzer şekilde "Apple 8" etiketli bazı görüntüler de "Apple 7" sanılarak sınıflandırılmıştır.




- **İkincil Karışıklıklar:** Adagrad gibi öğrenme yeteneği erken sönümlenen algoritmalarda, elma türleri dışındaki bazı birbirine yakın dokulu meyvelerde de (örneğin "Grape White 2" ile "Quince 3" veya "Blackberry 1" ile "BlackBerry 4" arasında) küçük çaplı sınıflandırma hataları gözlemlenmiştir.



### Tüm Algoritmaların Sınıflandırma Metrikleri Özeti


| Algoritma | Accuracy (Dogruluk) | Precision (Kesinlik) | Recall (Duyarlılık) | F1-Score |
|-----------|---------------------|----------------------|---------------------|----------|
| ADAM      | %86.13              | %88.77               | %86.13              | %85.94   |
| ADAGRAD   | %98.27              | %98.58               | %98.27              | %98.24   |
| ADAMAX    | %98.27              | %98.58               | %98.27              | %98.24   |
| SGD       | %6.67               | %0.48                | %6.67               | %0.89    |



#### 4. Sonuç ve Değerlendirme

Bu çalışmada, "Fruit-360" veri setinden rastgele seçilen 15 farklı meyve sınıfı üzerinde görüntü sınıflandırması yapmak amacıyla özel bir Evrişimli Sinir Ağı (CNN) mimarisi geliştirilmiştir. Modelin eğitim sürecinde Adam, Adamax, Adagrad ve SGD optimizasyon algoritmalarının performansları karşılaştırmalı olarak analiz edilmiştir. Elde edilen loss (kayıp), accuracy (doğruluk) eğrileri ve karmaşıklık matrisleri doğrultusunda aşağıdaki temel sonuçlara ulaşılmıştır:

- **Yakınsama Hızı (Convergence Speed):** Adaptif öğrenme oranına sahip olan Adam ve Adamax algoritmaları, modelin ağırlıklarını çok hızlı bir şekilde güncelleyerek henüz ilk 5 epok içerisinde kayıp değerini sıfıra yaklaştırmış ve %99'un üzerinde doğruluk oranlarına ulaşmıştır. Bu durum, veri setindeki özniteliklerin bu algoritmalar tarafından çok hızlı kavrandığını göstermektedir.



- **Öğrenme Kararlılığı:** Sabit bir öğrenme katsayısına sahip olan SGD, eğitim sürecine düşük bir doğrulukla başlamış ancak epok sayısı arttıkça istikrarlı bir şekilde öğrenmeye devam etmiştir. SGD yavaş yakınsamasına rağmen dalgalanma (noise) yaratmadan güvenilir bir öğrenme eğrisi çizmiştir. Öte yandan Adagrad, başlangıçta hızlı bir düşüş gösterse de, geçmiş gradyanların karelerinin birikmesi sebebiyle öğrenme oranının aşırı sönümlenmesi problemine maruz kalmış ve belirli bir doğruluk yüzdesinde takılı kalarak en düşük performansı sergilemiştir.
- **Sınıflandırma Hassasiyeti ve Sınıf Benzerlikleri:** Karmaşıklık matrisleri, algoritmaların ince detayları ayırt etme gücünü net bir şekilde ortaya koymuştur. Görsel olarak birbirine çok benzeyen "Apple 7" ve "Apple 8" gibi sınıfları ayırmakta SGD ve Adagrad zorlanırken, Adam ve Adamax bu sınıflar arasındaki ufak doku/reng farklılıklarını bile başarılı bir şekilde öğrenerek matrisin ana köşegeninde (diagonal) kusursuz bir yoğunlaşma sağlamıştır. "Nut 4" veya "Cactus fruit 1" gibi ayırt edici meyveler ise tüm algoritmalar tarafından kolayca sınıflandırılmıştır.

**Genel Değerlendirme:** Proje kapsamında kurulan CNN mimarisi ve kullanılan veri seti için en uygun ve verimli optimizasyon yöntemlerinin Adam ve Adamax olduğu tespit edilmiştir. Bu algoritmalar, hem eğitim süresini (hesaplama maliyetini) kısaltmış hem de yüksek doğruluk oranlarıyla modelin genelleme yeteneğini maksimize etmiştir.

Epoch

Epoch

Meyve Sınıflandırma Projesi: Final Performans Karşılaştırması

| Algoritma | Eğitim Başarısı | Validation Başarısı | Final Kayıp (Loss) |
|-----------|-----------------|---------------------|--------------------|
| ADAM      | %92.13          | %97.47              | 0.042330           |
| ADAGRAD   | %96.53          | %98.27              | 0.079019           |
| ADAMAX    | %94.93          | %98.27              | 0.067414           |
| SGD       | %57.47          | %73.20              | 0.806217           |

## 5. Referanslar

- Mureşan, H., & Oltean, M. (2018). Fruit recognition from images using deep learning. *Acta Univ. Sapientiae, Informatica*, 10(1), 26-42.
- Kingma, D. P., & Ba, J. (2014). Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*.
- Duchi, J., Hazan, E., & Singer, Y. (2011). Adaptive subgradient methods for online learning and stochastic optimization. *Journal of Machine Learning Research*, 12(Jul), 2121-2159.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.